# 08-哨兵集群:哨兵挂了,主从库还能切换吗?

你好,我是蒋德钧。

上节课,我们学习了哨兵机制,它可以实现主从库的自动切换。通过部署多个实例,就形成了一个哨兵集群。哨兵集群中的多个实例共同判断,可以降低对主库下线的误判率。

但是,我们还是要考虑一个问题:如果有哨兵实例在运行时发生了故障,主从库还能正常切换吗?

实际上,一旦多个实例组成了**哨兵集群**,即使有哨兵实例出现故障挂掉了,其他哨兵还能继续协作完成主从 库切换的工作,包括判定主库是不是处于下线状态,选择新主库,以及通知从库和客户端。

如果你部署过哨兵集群的话就会知道,在配置哨兵的信息时,我们只需要用到下面的这个配置项,设置**主库的IP**和**端口**,并没有配置其他哨兵的连接信息。

```
sentinel monitor <master-name> <ip> <redis-port> <quorum>
```

这些哨兵实例既然都不知道彼此的地址,又是怎么组成集群的呢?要弄明白这个问题,我们就需要学习一下哨兵集群的组成和运行机制了。

# 基于pub/sub机制的哨兵集群组成

哨兵实例之间可以相互发现,要归功于Redis提供的pub/sub机制,也就是发布/订阅机制。

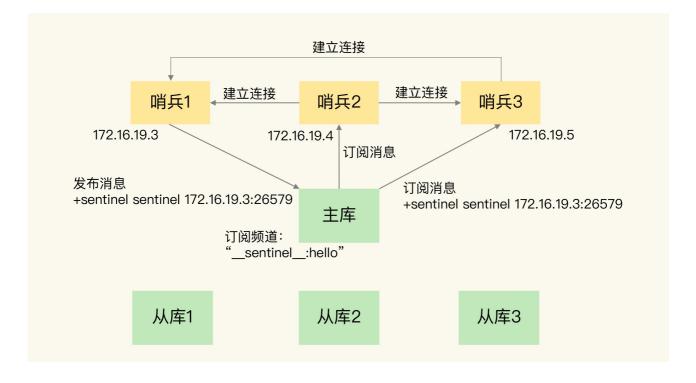
哨兵只要和主库建立起了连接,就可以在主库上发布消息了,比如说发布它自己的连接信息(IP和端口)。 同时,它也可以从主库上订阅消息,获得其他哨兵发布的连接信息。当多个哨兵实例都在主库上做了发布和 订阅操作后,它们之间就能知道彼此的IP地址和端口。

除了哨兵实例,我们自己编写的应用程序也可以通过Redis进行消息的发布和订阅。所以,为了区分不同应用的消息,Redis会以频道的形式,对这些消息进行分门别类的管理。所谓的频道,实际上就是消息的类别。当消息类别相同时,它们就属于同一个频道。反之,就属于不同的频道。**只有订阅了同一个频道的应用,才能通过发布的消息进行信息交换**。

在主从集群中,主库上有一个名为"\_\_sentinel\_\_:hello"的频道,不同哨兵就是通过它来相互发现, 实现互相通信的。

我来举个例子,具体说明一下。在下图中,哨兵1把自己的IP(172.16.19.3)和端口(26579)发布 到 "\_\_sentinel\_\_:hello" 频道上,哨兵2和3订阅了该频道。那么此时,哨兵2和3就可以从这个频道直接获取哨兵1的IP地址和端口号。

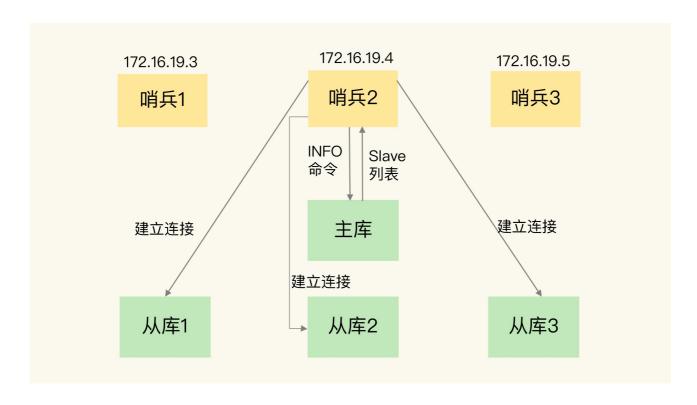
然后,哨兵2、3可以和哨兵1建立网络连接。通过这个方式,哨兵2和3也可以建立网络连接,这样一来,哨兵集群就形成了。它们相互间可以通过网络连接进行通信,比如说对主库有没有下线这件事儿进行判断和协商。



哨兵除了彼此之间建立起连接形成集群外,还需要和从库建立连接。这是因为,在哨兵的监控任务中,它需要对主从库都进行心跳判断,而且在主从库切换完成后,它还需要通知从库,让它们和新主库进行同步。

### 那么,**哨兵是如何知道从库的IP地址和端口的呢?**

这是由哨兵向主库发送INFO命令来完成的。就像下图所示,哨兵2给主库发送INFO命令,主库接受到这个命令后,就会把从库列表返回给哨兵。接着,哨兵就可以根据从库列表中的连接信息,和每个从库建立连接,并在这个连接上持续地对从库进行监控。哨兵1和3可以通过相同的方法和从库建立连接。



你看,通过pub/sub机制,哨兵之间可以组成集群,同时,哨兵又通过INFO命令,获得了从库连接信息,也能和从库建立连接,并进行监控了。

但是,哨兵不能只和主、从库连接。因为,主从库切换后,客户端也需要知道新主库的连接信息,才能向新 主库发送请求操作。所以,哨兵还需要完成把新主库的信息告诉客户端这个任务。 而且,在实际使用哨兵时,我们有时会遇到这样的问题:如何在客户端通过监控了解哨兵进行主从切换的过程呢?比如说,主从切换进行到哪一步了?这其实就是要求,客户端能够获取到哨兵集群在监控、选主、切换这个过程中发生的各种事件。

此时,我们仍然可以依赖pub/sub机制,来帮助我们完成哨兵和客户端间的信息同步。

## 基于pub/sub机制的客户端事件通知

从本质上说,哨兵就是一个运行在特定模式下的Redis实例,只不过它并不服务请求操作,只是完成监控、 选主和通知的任务。所以,每个哨兵实例也提供pub/sub机制,客户端可以从哨兵订阅消息。哨兵提供的消息订阅频道有很多,不同频道包含了主从库切换过程中的不同关键事件。

频道有这么多,一下子全部学习容易丢失重点。为了减轻你的学习压力,我把重要的频道汇总在了一起,涉 及几个关键事件,包括主库下线判断、新主库选定、从库重新配置。

事件	相关频道		
主库下线事件	+sdown(实例进入"主观下线"状态)		
	-sdown(实例退出"主观下线"状态)		
	+odown(实例进入"客观下线"状态)		
	-odown(实例退出"客观下线"状态)		
从库重新配置事件	+slave-reconf-sent (哨兵发送SLAVEOF命令重新配置从库)		
	+slave-reconf-inprog (从库配置了新主库,但尚未进行同步)		
	+slave-reconf-done(从库配置了新主库,且和新主库完成同步)		
新主库切换	+switch-master(主库地址发生变化)		

知道了这些频道之后,你就可以**让客户端从哨兵这里订阅消息**了。具体的操作步骤是,客户端读取哨兵的配置文件后,可以获得哨兵的地址和端口,和哨兵建立网络连接。然后,我们可以在客户端执行订阅命令,来获取不同的事件消息。

举个例子,你可以执行如下命令,来订阅"所有实例进入客观下线状态的事件":

SUBSCRIBE +odown

当然,你也可以执行如下命令,订阅所有的事件:

当哨兵把新主库选择出来后,客户端就会看到下面的switch-master事件。这个事件表示主库已经切换了, 新主库的IP地址和端口信息已经有了。这个时候,客户端就可以用这里面的新主库地址和端口进行通信了。

```
switch-master <master name> <oldip> <oldport> <newip> <newport>
```

有了这些事件通知,客户端不仅可以在主从切换后得到新主库的连接信息,还可以监控到主从库切换过程中 发生的各个重要事件。这样,客户端就可以知道主从切换进行到哪一步了,有助于了解切换进度。

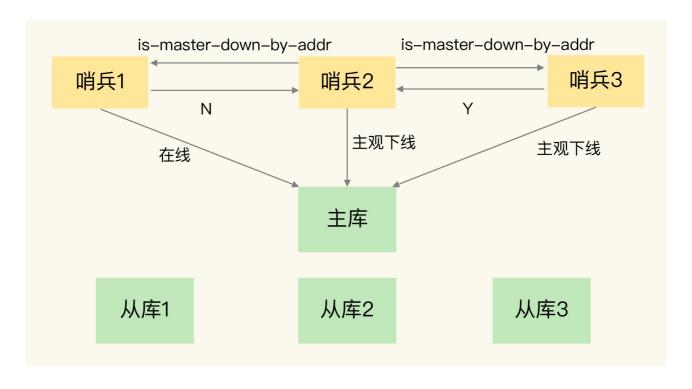
好了,有了pub/sub机制,哨兵和哨兵之间、哨兵和从库之间、哨兵和客户端之间就都能建立起连接了,再加上我们上节课介绍主库下线判断和选主依据,哨兵集群的监控、选主和通知三个任务就基本可以正常工作了。不过,我们还需要考虑一个问题:主库故障以后,哨兵集群有多个实例,那怎么确定由哪个哨兵来进行实际的主从切换呢?

## 由哪个哨兵执行主从切换?

确定由哪个哨兵执行主从切换的过程,和主库"客观下线"的判断过程类似,也是一个"投票仲裁"的过程。在具体了解这个过程前,我们再来看下,判断"客观下线"的仲裁过程。

哨兵集群要判定主库"客观下线",需要有一定数量的实例都认为该主库已经"主观下线"了。我在上节课 向你介绍了判断"客观下线"的原则,接下来,我介绍下具体的判断过程。

任何一个实例只要自身判断主库"主观下线"后,就会给其他实例发送is-master-down-by-addr命令。接着,其他实例会根据自己和主库的连接情况,做出Y或N的响应,Y相当于赞成票,N相当于反对票。



一个哨兵获得了仲裁所需的赞成票数后,就可以标记主库为"客观下线"。这个所需的赞成票数是通过哨兵配置文件中的quorum配置项设定的。例如,现在有5个哨兵,quorum配置的是3,那么,一个哨兵需要3张

赞成票,就可以标记主库为"客观下线"了。这3张赞成票包括哨兵自己的一张赞成票和另外两个哨兵的赞成票。

此时,这个哨兵就可以再给其他哨兵发送命令,表明希望由自己来执行主从切换,并让所有其他哨兵进行投票。这个投票过程称为"Leader选举"。因为最终执行主从切换的哨兵称为Leader,投票过程就是确定Leader。

在投票过程中,任何一个想成为Leader的哨兵,要满足两个条件:第一,拿到半数以上的赞成票;第二,拿到的票数同时还需要大于等于哨兵配置文件中的quorum值。以3个哨兵为例,假设此时的quorum设置为2,那么,任何一个想成为Leader的哨兵只要拿到2张赞成票,就可以了。

这么说你可能还不太好理解,我再画一张图片,展示一下3个哨兵、quorum为2的选举过程。

时间	哨兵1 (S1)	哨兵2(S2)	哨兵3(S3)
T1	给自己投1票Y 向S2、S3发投票请求, 表示要成为Leader		
Т2			给自己投1票Y 向S1、S2发投票请求, 表示要成为Leader
Т3	收到S3的请求,回复N	收到S3的请求,回复Y	
T4		收到S1的请求,回复N	
T5	1票Y, 1票N		2票Y,成为Leader

在T1时刻,S1判断主库为"客观下线",它想成为Leader,就先给自己投一张赞成票,然后分别向S2和S3 发送命令,表示要成为Leader。

在T2时刻,S3判断主库为"客观下线",它也想成为Leader,所以也先给自己投一张赞成票,再分别向S1和S2发送命令,表示要成为Leader。

在T3时刻,S1收到了S3的Leader投票请求。因为S1已经给自己投了一票Y,所以它不能再给其他哨兵投赞成票了,所以S1回复N表示不同意。同时,S2收到了T2时S3发送的Leader投票请求。因为S2之前没有投过票,它会给第一个向它发送投票请求的哨兵回复Y,给后续再发送投票请求的哨兵回复N,所以,在T3时,S2回复S3,同意S3成为Leader。

在T4时刻,S2才收到T1时S1发送的投票命令。因为S2已经在T3时同意了S3的投票请求,此时,S2给S1回复N,表示不同意S1成为Leader。发生这种情况,是因为S3和S2之间的网络传输正常,而S1和S2之间的网络传输可能正好拥塞了,导致投票请求传输慢了。

最后,在T5时刻,S1得到的票数是来自它自己的一票Y和来自S2的一票N。而S3除了自己的赞成票Y以外,还收到了来自S2的一票Y。此时,S3不仅获得了半数以上的Leader赞成票,也达到预设的quorum值(quorum为2),所以它最终成为了Leader。接着,S3会开始执行选主操作,而且在选定新主库后,会给其他从库和客户端通知新主库的信息。

如果S3没有拿到2票Y,那么这轮投票就不会产生Leader。哨兵集群会等待一段时间(也就是哨兵故障转移超时时间的2倍),再重新选举。这是因为,哨兵集群能够进行成功投票,很大程度上依赖于选举命令的正常网络传播。如果网络压力较大或有短时堵塞,就可能导致没有一个哨兵能拿到半数以上的赞成票。所以,等到网络拥塞好转之后,再进行投票选举,成功的概率就会增加。

需要注意的是,如果哨兵集群只有2个实例,此时,一个哨兵要想成为Leader,必须获得2票,而不是1票。 所以,如果有个哨兵挂掉了,那么,此时的集群是无法进行主从库切换的。因此,通常我们至少会配置3个 哨兵实例。这一点很重要,你在实际应用时可不能忽略了。

## 小结

通常,我们在解决一个系统问题的时候,会引入一个新机制,或者设计一层新功能,就像我们在这两节课学习的内容:为了实现主从切换,我们引入了哨兵;为了避免单个哨兵故障后无法进行主从切换,以及为了减少误判率,又引入了哨兵集群;哨兵集群又需要有一些机制来支撑它的正常运行。

这节课上,我就向你介绍了支持哨兵集群的这些关键机制,包括:

- 基于pub/sub机制的哨兵集群组成过程;
- 基于INFO命令的从库列表,这可以帮助哨兵和从库建立连接;
- 基于哨兵自身的pub/sub功能,这实现了客户端和哨兵之间的事件通知。

对于主从切换,当然不是哪个哨兵想执行就可以执行的,否则就乱套了。所以,这就需要哨兵集群在判断了 主库"客观下线"后,经过投票仲裁,选举一个Leader出来,由它负责实际的主从切换,即由它来完成新 主库的选择以及通知从库与客户端。

最后,我想再给你分享一个经验:**要保证所有哨兵实例的配置是一致的,尤其是主观下线的判断值downafter-milliseconds**。我们曾经就踩过一个"坑"。当时,在我们的项目中,因为这个值在不同的哨兵实例上配置不一致,导致哨兵集群一直没有对有故障的主库形成共识,也就没有及时切换主库,最终的结果就是集群服务不稳定。所以,你一定不要忽略这条看似简单的经验。

### 每课一问

这节课上,我给你提一个小问题。

假设有一个Redis集群,是"一主四从",同时配置了包含5个哨兵实例的集群,quorum值设为2。在运行过程中,如果有3个哨兵实例都发生故障了,此时,Redis主库如果有故障,还能正确地判断主库"客观下线"吗?如果可以的话,还能进行主从库自动切换吗?此外,哨兵实例是不是越多越好呢,如果同时调大down-after-milliseconds值,对减少误判是不是也有好处呢?

欢迎你在留言区跟我交流讨论。如果你身边也有要学习哨兵集群相关知识点的朋友,也欢迎你能帮我把今天的内容分享给他们,帮助他们一起解决问题。我们下节课见。

## 精选留言:

• Kaito 2020-08-21 12:01:45

Redis 1主4从,5个哨兵,哨兵配置quorum为2,如果3个哨兵故障,当主库宕机时,哨兵能否判断主库 "客观下线"?能否自动切换?

经过实际测试,我的结论如下:

- 1、哨兵集群可以判定主库"主观下线"。由于quorum=2,所以当一个哨兵判断主库"主观下线"后,询问另外一个哨兵后也会得到同样的结果,2个哨兵都判定"主观下线",达到了quorum的值,因此,哨兵集群可以判定主库为"客观下线"。
- 2、但哨兵不能完成主从切换。哨兵标记主库"客观下线后",在选举"哨兵领导者"时,一个哨兵必须拿到超过多数的选票(5/2+1=3票)。但目前只有2个哨兵活着,无论怎么投票,一个哨兵最多只能拿到2票,永远无法达到多数选票的结果。

但是投票选举过程的细节并不是大家认为的:每个哨兵各自1票,这个情况是不一定的。下面具体说一下 :

场景a: 哨兵A先判定主库"主观下线",然后马上询问哨兵B(注意,此时哨兵B只是被动接受询问,并没有去询问哨兵A,也就是它还没有进入判定"客观下线"的流程),哨兵B回复主库已"主观下线",达到quorum=2后哨兵A此时可以判定主库"客观下线"。此时,哨兵A马上可以向其他哨兵发起成为"哨兵领导者"的投票,哨兵B收到投票请求后,由于自己还没有询问哨兵A进入判定"客观下线"的流程,所以哨兵B是可以给哨兵A投票确认的,这样哨兵A就已经拿到2票了。等稍后哨兵B也判定"主观下线"后想成为领导者时,因为它已经给别人投过票了,所以这一轮自己就不能再成为领导者了。

场景b: 哨兵A和哨兵B同时判定主库"主观下线",然后同时询问对方后都得到可以"客观下线"的结论,此时它们各自给自己投上1票后,然后向其他哨兵发起投票请求,但是因为各自都给自己投过票了,因此各自都拒绝了对方的投票请求,这样2个哨兵各自持有1票。

场景a是1个哨兵拿到2票,场景b是2个哨兵各自有1票,这2种情况都不满足大多数选票(3票)的结果,因此无法完成主从切换。

经过测试发现,场景b发生的概率非常小,只有2个哨兵同时进入判定"主观下线"的流程时才可以发生。我测试几次后发现,都是复现的场景a。

哨兵实例是不是越多越好?

并不是,我们也看到了,哨兵在判定"主观下线"和选举"哨兵领导者"时,都需要和其他节点进行通信,交换信息,哨兵实例越多,通信的次数也就越多,而且部署多个哨兵时,会分布在不同机器上,节点越多带来的机器故障风险也会越大,这些问题都会影响到哨兵的通信和选举,出问题时也就意味着选举时间会变长,切换主从的时间变久。

调大down-after-milliseconds值,对减少误判是不是有好处?

是有好处的,适当调大down-after-milliseconds值,当哨兵与主库之间网络存在短时波动时,可以降低误判的概率。但是调大down-after-milliseconds值也意味着主从切换的时间会变长,对业务的影响时间越久,我们需要根据实际场景进行权衡,设置合理的阈值。 [25赞]

- Darren 2020-08-21 09:59:00
  - 1、可以正确的判断主库"客观下线",以为其中一个哨兵已经获得了"客观下线"所需要的投票数;

- 2、不能进行自动的主从切换,因为在主从切换的时候,必须选择出一个主哨兵,但是选择主哨兵有2个条件:
- 2.1 拿到半数以上的赞成票;
- 2.2 拿到的票数同时还需要大于等于哨兵配置文件中的 quorum 值。

此时可以满足投票数,但是拿不到半数以上的投票,因此无法选出主哨兵,所以无法进行主从切换。

- 3、哨兵的实例不是越多越好,因为哨兵的选举使用的是Raft协议,这个协议是Paxos协议的变种,这种协议在选主时,需要所有的节点参与投票,所以节点越多,选举耗时可能就会更久,所以根据对服务SLA的要求,评估一个节点可能出现问题的概率,选择合适的哨兵数量。
- 4、down-after-milliseconds不是越大越好的,虽然可以减少误判的概率,但是问题真正发生时,服务的不可用状态也会更久,所以down-after-milliseconds要根据真实的业务场景,进行取舍。 [4赞]

#### kingdompeak 2020-08-21 07:41:06

- 1.可以判断主库"客观下线"。比如哨兵实例1判断主库为客观下线,然后向哨兵实例2发送is-master-down-by-addr命令,如果哨兵实例2此时也判断主库为客观下线,就会返回Y,此时哨兵实例1就会有两个Y(包括自己的),满足配置项quorum,所以就可以判断主库客观下线。
- 2.不能进行主从进行主从切换前需要选执行切换操作的Leader。由于两个哨兵实例在选Leader的事情上都只会给自己投票,所以各自的得票数只能为1,满足不了成为Leader的两个条件(1.得票数大于哨兵实例数的一半;2.满足quorum配置项),所以选不出Leader,自然无法执行主从切换。
- 3.调大此参数对误判有好处,由于存活的哨兵实例只有两个,如果恰好某段时间,两个实例与主库的网络连接不好,则很容易都将其标记为主观下线,进而就标记为客观下线了,进而就产生了误判,时间长点,在哨兵实例少的情况下会减少误判情况的发生。[3赞]

### • Q 2020-08-21 09:00:43

干货满满。。最近一直在测试哨兵集群,get 到一个点: 自己还要给自己投一票! 也就是每个哨兵只有一次投票权,投自己或别人! [1赞]

• 范闲 2020-08-22 09:26:47

哨兵判断下线分为可能下线和确定下线两种状态。

在课后的例子中,5个哨兵正常2个,异常3个,qurum为2(判断确定下线的哨兵数目)

根据主从选举要求必须半数以上的节点同意,即要求数量大于N/2+1。此例中是5/2+1=3,而只有2个哨兵活着因此不可能完成主从切换。

而确定下线的数目为2,2个哨兵可以完成确定下线的判断。

作者回复2020-08-22 13:35:02

理解到位了!

不过,一般我们还是叫主观下线和客观下线更多些。。

• 小喵喵 2020-08-21 14:40:08

#### 老师请教下:

- 1、图示哨兵选举过程中,选举的结果取决于S2的投票,如果S2也投给自己,并且每轮投票都是只投给自己,岂不是无法选出"Leader",是不是这个过程从了死循环呢?
- 2、投票投给谁,依据是什么?
- 漫步oo0云端 2020-08-21 14:12:34

老师: 所以,每个哨兵实例也提供 pub/sub 机制,客户端可以从哨兵订阅消息。

我对这句话不太理解,客户端不是直接连主库操作吗?是使用主库IP连redis的,怎么会从哨兵订阅消息呢?是从主库拿到的哨兵的IP和端口号,连接的吗?但是客户端应该不会做这样的事情吧?我有点疑惑,请老师指教。

• 盟讯 2020-08-21 12:00:57

可以判断客观下线,两个哨兵都会判断"主观下线",达到仲裁值所需要的数: 2。 不会进行主从切换,因为在哨兵选择leader时,每一个哨兵都会选择自己,票数问题相等

哨兵实例不是越多越好,实例越多通信越频繁,会造成网络拥塞。

down-after-milliseconds的值高大对误判有好处,调大会对网络不稳定的导致通信不畅有好处,但是当主库出现故障时

主从切换操作过程会增长,而且监控不迅速

• 倪大人 2020-08-21 10:45:34

问个问题,文章里的S1、S2、S3那张图,为什么S2不能给自己投票?是不是在"客观下线"中投了赞成票的哨兵才能竞选leader?

• zhou 2020-08-21 10:05:19

因为只有两个实例,quorum 是 2,所以两个实例必须都判断为主观下线,才会确认为客观下线。

但只要其中一个实例确认为客观下线,另一个实例必然也会确认为客观下线。此时两个实例都希望申请成为 Leader,先给自己投票,然后请求对方投票。由于都已给自己投过票,无法给其他实例投票,最终导致这一轮无法产生 Leader。

等待一段时间后,如果其中一个实例先发出 Leader 申请,可能会得到另一个实例的投票,该实例就会成为 Leader,可以进行选主。

riryoutexi 2020-08-21 09:40:15整个哨兵集群都挂了,还会主从切换吗

作者回复2020-08-22 00:31:30 哨兵都挂了,无能为力了。。。

- Kirito 2020-08-21 09:28:24会有3个哨兵都投给自己的情况吗?那不是平票了☺
- 小贤 2020-08-21 08:51:25down-after-milliseconds 这个参数一般设置多大合适呢?
- test 2020-08-21 00:50:24
  可以判断客观下线,但是无法进行选主。调大参数对误判有好处。